26-2 SKKAI Speech AI session

Qwen3-ASR 기반 실시간 동시통역 시스템 STiTy 설명회



MOTIVATION

연구 배경

“서로 언어가 다르더라도 언어 장벽 없이 실시간으로 소통 가능한“ 미래를 꿈꿉니다

완전 자동화 실현

버튼을 누르지 않아도, 발화 종료를 명시하지 않아도
자연스러운 소통이 가능합니다.

대화 감지, 언어 감지를 통해 자동화 시스템을 구현합니다.

초저지연 달성

의미가 확정될 때마다 즉시 출력하여, 최대한 빠르게
상대에게 정보를 전달합니다.

한 문장이 끝나지 않더라도, <> 의미가 분절되는 지점이 있습니다.



실시간 대화는 얼마나 빨라야 하는가

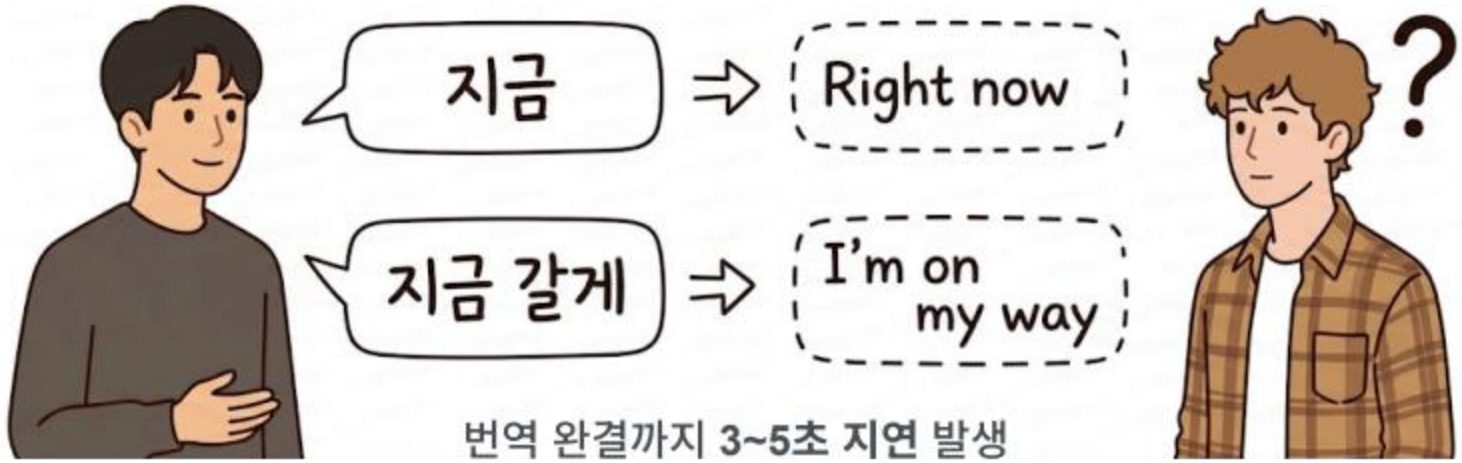
실제 대화의 발화 간격은 약 **200ms**로 매우 짧아, 실시간 대화 시스템은 **0.5초 미만**의 즉각적 결과를 제공해야 합니다.
현재 상용 회의 기록용 STT는 3~5초 지연을 피하기 어렵고, 출력을 통째로 교체(rewrite)하는 2-pass 구조로
동시 통역형 대화에서는 부적합합니다.

요구조건 1

0.5초 미만의 지연

요구조건 2

출력 고정성 (재수정 없음)



발화가 진행됨에 따라 출력이 통째로 교체

동시 통역 부적합

BACKGROUND – 선행 단계

Whisper 기반 스트리밍 개조, 그러나 남은 한계

STAGE 1 · Original

비스트리밍

7.42s

STAGE 2 · Chunked

청크 기반 스트리밍

3.45s

STAGE 3 · Simul-Streaming

Attention-peak 기반

0.185s

구조적 한계

① **분절 자립성 부재** —- 의미 분절이 VAD · CIF · 종결부호 · 키워드 사전 등 외부 규칙에 전적으로 의존

② **인식률 저하** —- 스트리밍 전환 과정에서 너무 짧은 분절로 인한 문맥 부족으로 정확도 손실

③ **다국어 확장 제약** —- 언어별 규칙 · 사전 설계 비용 누적

즉, 의미 경계 판단을 외부 규칙이 아닌 **모델 내부의 학습된 표현으로 이관**하고,

이를 **스트리밍에 적합한 백본** 위에서 수행할 필요성 존재

INTRODUCTION

두 가지 요구사항을 지키며, 세 가지 목표로

요구조건 1

0.5초 미만의 지연

+

요구조건 2

출력 고정성 (재수정 없음)

연구 목표

1

스트리밍 네이티브 백본

Qwen3-ASR 1.7B 채택으로 입출력 전 구간에서 스트리밍 처리가 가능한 구조 확보

2

분절 자립성

의미 경계 판정을 모델이 직접 수행하도록 학습
— 외부 규칙 없이도 지연 · 고정성 확보

3

지연 · 번역 품질 동시 개선 + 검증

지연을 낮추면서 인식 품질도 함께 개선,
다국어 환경에서 파이프라인 검증

METHODOLOGY — STEP 1

백본 전환

FROM

WHISPER

→

TO

Qwen3-ASR 1.7B

- 스트리밍 입출력 지원, 언어 프리픽스 조건화 내장
- 개조 복잡도를 크게 낮추고 <SEG> 토큰 학습의 확장 지점 확보

SYSTEM PIPELINE — 전체 처리 흐름



METHODOLOGY — STEP 2

모델 내재적 의미 분절 — <SEG> 토큰

의미 경계에 <SEG> 토큰을 삽입한 데이터로 SFT (지도 파인튜닝)를 수행합니다.

모델이 디코딩 중 <SEG>를 직접 생성하는 순간이 곧 **커밋**입니다.

외부 규칙 없이, 토큰 한 번으로 커밋을 결정합니다.

ORIGINAL

온점(.) 또는 VAD 무음 0.8초 이상 → 커밋

학교 가는 길에 비가 내렸어요 . 그래서 우산을 챙겼어요

↑

온점 감지, 커밋

학교 가는 길에 비가 내렸어요 ...(0.8s 무음) 그래서 우산을 챙겼어요

↑

무음 감지, 커밋

FINETUNED

<SEG> 토큰 탐지 시 즉시 커밋

VAD·문장부호 없이 토큰 한 번으로 결정

학교 가는 길에 비가 내렸어요 <SEG> 그래서 우산을 챙겼어요

↑

SEG 생성, 즉시 커밋

커밋 정책 우선순위 1순위 <SEG> 토큰 | 2순위 VAD 침묵 (~0.8s) | 3순위 종결부호 (호환)

METHODOLOGY — STEP 3

실시간 번역 정책 — GPT 기반 보정 · 문맥 반영 번역

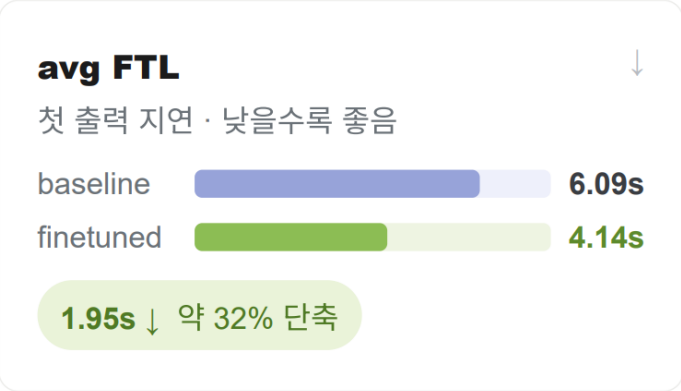
- <SEG> 토큰 감지로 분절된 문장의 문맥이 손실되지 않도록 문맥 유지
- 오인식 교정과 번역을 단일 호출로 통합하며 토큰 소모 절감

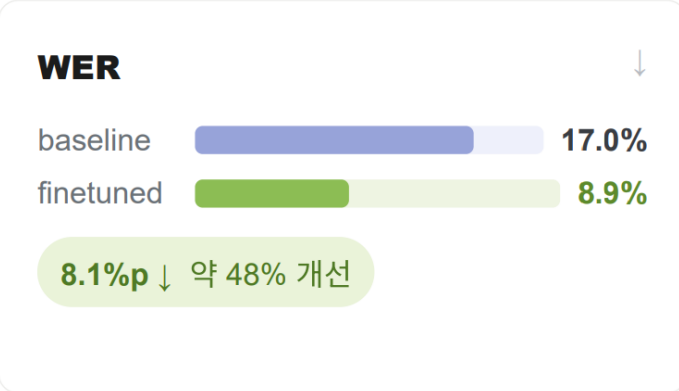


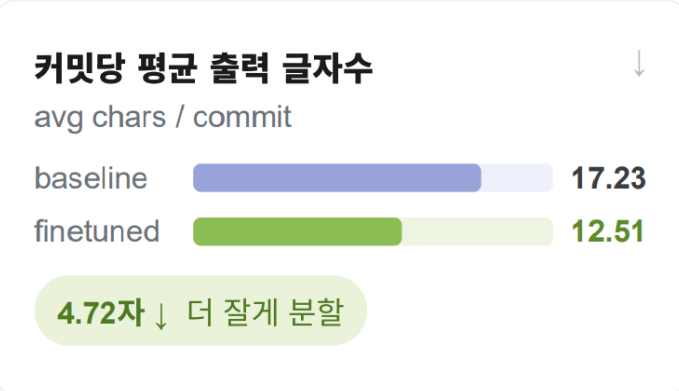
EXPERIMENTS

테스트 결과

테스트 벤치마크 : LibriSpeech (영어 낭독 데이터셋), 851개 클립 (약 1시간)







- First Token Latency (FTL) : 사용자 음성 입력부터 화면에 첫 토큰이 표시될 때까지의 지연
- Word Error Rate (WER) : 출력 텍스트와 정답 텍스트 간 단어 수준에서의 오류 수준

- Baseline : Qwen3-ASR 1.7B 순정 파이프라인
- Finetuned : <SEG> 지도학습 merge 모델

EXPERIMENTS

테스트 결과

테스트 벤치마크 : DailyTalk (영어 일상 대화 데이터셋), 22개 챕터 (약 30분)

평가 사용 모델 : gpt-5.4-mini

Method	Avg Score
GDT (no context)	77.64
GPT context	**90.77**

번역 품질 평가 프롬프트

실시간 영-한 번역을 문맥 일관성 0 ~ 100점 사이로 채점

1. 문장 간 일관성 – 대명사, 지시 표현, 인과 · 시간 순서
2. 용어 일관성 – 반복되는 전문 용어, 고유명사, 인물명
3. 중의적 어휘 – 이전 문맥 기반 판단하여 올바른 사용
4. 어조 · 격식 일관성 – 어조를 전반적으로 안정되게 유지

RESULTS

프로젝트 결과 정리

1. **스트리밍 백본 + 다국어 검증 환경 마련 –**

   Qwen3-ASR 1.7B로 백본 전환 및 파이프라인 구성

   영 · 한 · 일 · 중 · 스페인어 5개 언어 벤치마크 구축

2. **분절 판단의 모델 내재화 –**

   <SEG> 토큰 파인튜닝으로 커밋의 93.3%가 모델이 생성한 <SEG>에서 발생

   WER 약 48% ↓, FTL 약 32% ↓ 달성

프로젝트 결과 정리

3. 실환경 적용과 사회적 기여 가능성 –

25-2학기 : Time (학내 영어토론동아리) 정기세션, IBM Qiskit Fall Fest 실사용

26-1학기 : 음성 전문 스타트업 <MAGO> 협업 네트워킹 및 URP 연계 학술연구



IBM Qiskit Fall Fest 실사용



<MAGO> 음성 스타트업 협업 네트워킹

26-2 과제

1. 노이즈 제거, 화자 분리 등 별도 레이어 추가 + 해당 상황을 테스트할 수 있는 데이터셋 탐색
2. 라벨링 에이전트 검증 및 파인튜닝 추가 진행 (데이터 라벨링, 수집 필요)
3. Encoder-level 분절 or Latent Space Dynamic Chunking 연구
4. 기존 파이프라인 개선 및 테스트 (wer, latency, laal, bleu, comet)
5. CI/CD – 각 상황별 검증 테스트셋 및 자동 검증 체계 구축

STiTy

사용하는 툴

Jira



slack

APPENDIX

부록

Qwen3-ASR 1.7B

알리바바에서 26.01 출시한 스트리밍 STT 모델

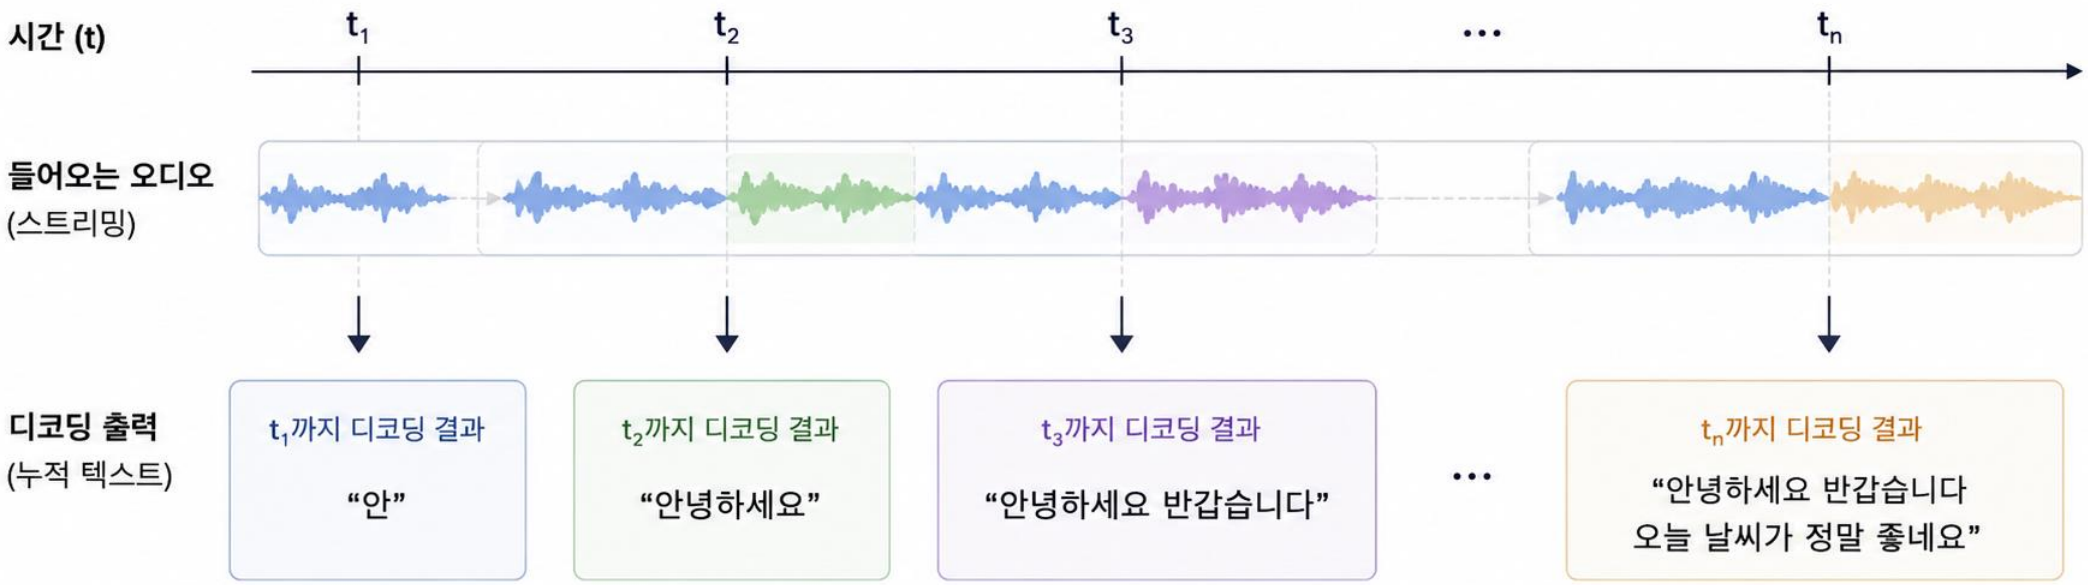
기존 Qwen3 LLM 을 바탕으로 오디오 인코더를 넣어 STT 모델로 개조

1. 고정 청크 단위 (기본값 2초)로 스트리밍 입출력 지원
2. 증분 및 누적 디코딩
3. 타임스탬프 제공 X (별도의 서브 모델 Qwen3-ForcedAligner-0.6B 존재)
4. 매 청크 끝마다 온점 생성

부록

Qwen3-ASR 증분 디코딩 (Incremental Decoding)

오디오가 계속 들어오는 동안, 디코더는 이전까지 모두 들어온 오디오(누적된 컨텍스트)를 대상으로 디코딩을 수행합니다.



각 시점 t_k 에서의 디코딩은 **0 ~ t_k** 까지 들어온 모든 오디오를 기반으로 수행됩니다.

APPENDIX

부록

1) 커밋 로직



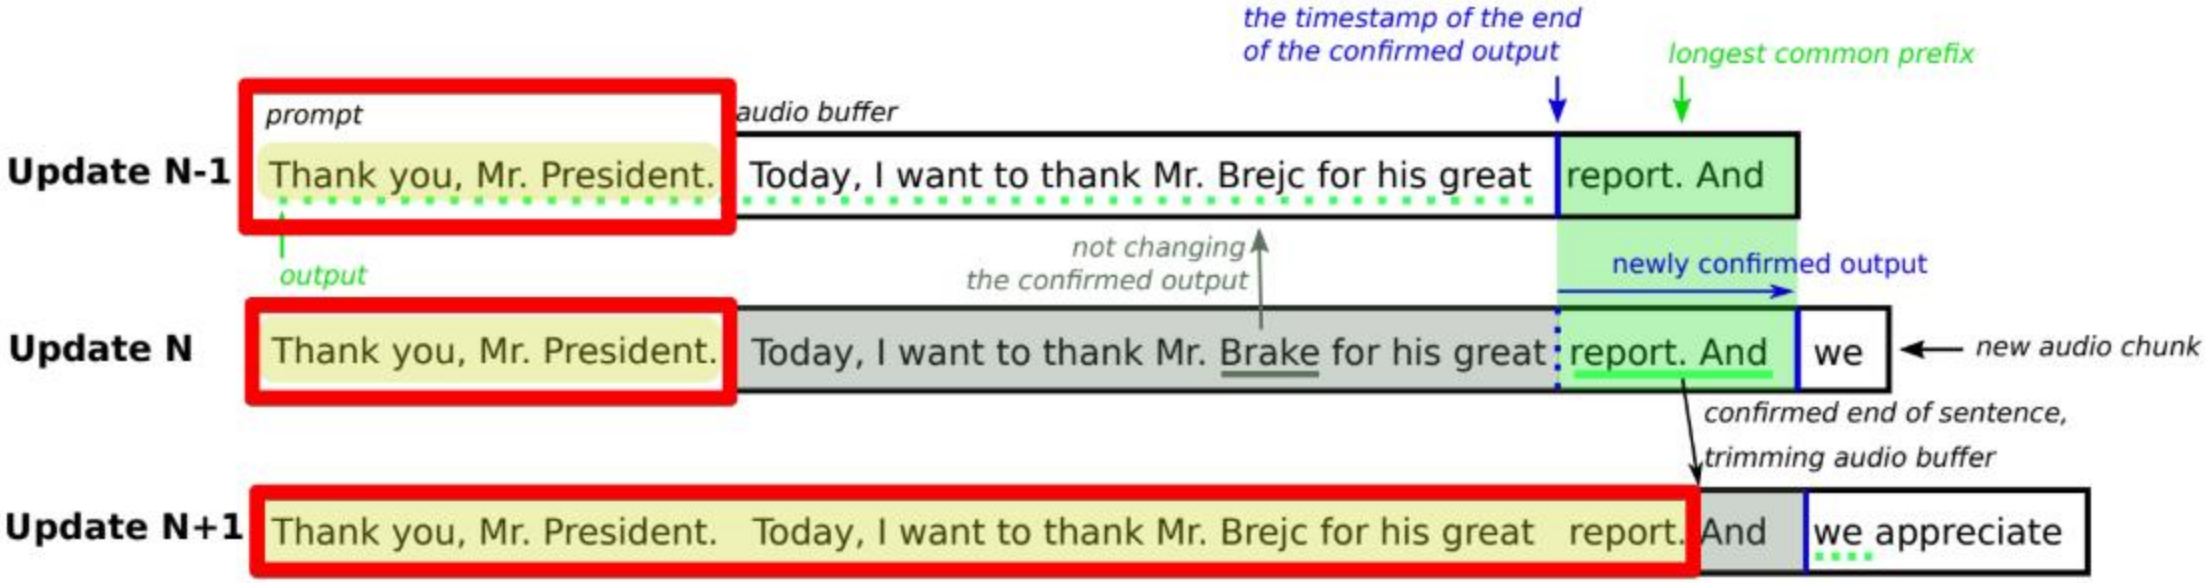
DOT commit path

규칙1: 마침표가 prefix 안이면 애초에 안 바뀔 거라 즉시 확정
규칙2: 직전 청크에도 같은 경계 있었으면 확정 (Local-Agreement)
규칙3: 오디오 늘어도 가설 토큰 수 정체(stall) → 종료로 간주해 확정
규칙4: finish 시점엔 무조건 확정(더 들을 오디오 없으니 유예 의미 없음)

SEG, VAD commit path: 해당 이벤트 감지 시 커밋

부록

Local-Agreement



부록

2) 오디오 버퍼 플러쉬

Qwen3-ASR은 타임스탬프를 실시간으로 제공하지 않기 때문에 DOT, SEG가 발생한 정확한 위치를 실시간으로 찾을 수 없다.
또한, flush 시 유입되는 오디오를 받기 위해선 2 slot이 필요하다

VAD path : 발생 시 즉시 slot 전환

DOT path : 이전 청크의 끝이 온점이면서 위치 유지

SEG path : 이전 청크의 끝이 SEG이면서 위치 유지

부록

사용하는 지표

1. ASR (Automatic Speech Recognition)

- WER (Word Error Rate) ↓: 음성 인식 결과와 정답 간의 단어 오류율을 측정
- Latency (FTL, First Token Latency) ↓ : 음성 입력이 시작된 후 첫 번째 인식 결과(Token)가 출력되기까지 걸리는 시간

2. StreamST (Streaming Speech-to-Text Translation)

- LAAL (Length-Adaptive Average Lagging) ↓ : 실시간 번역에서 번역 출력이 입력 음성을 얼마나 지연되어 따라가는지 측정
- BLEU (Bilingual Evaluation Understudy) ↑: 생성된 번역과 정답 번역 간의 n-gram 일치도를 기반으로 번역 품질을 평가
- COMET ↑ : 번역 결과와 정답(또는 원문)을 바탕으로 의미적 유사성과 번역 품질을 평가하는 신경망 기반 지표